

Эвристические подходы к адаптации чебышёвского ускорения для задач общей выпуклой оптимизации

Дмитрий Егоров

СПбГУ, Математико-механический факультет

Апрель 2026

Теорема Янга (Young's), 1950

Рассмотрим квадратичную форму $f(x) = \frac{1}{2}x^T Ax - b^T x$, где A имеет число обусловленности $\kappa = \frac{L}{m}$.

Градиентный спуск: $x_{T+1} = x_T - \alpha_T \nabla f(x_T)$, x^* — точка минимума.

Выберем $\alpha_T = \frac{1}{\lambda_t}$, где λ_t — корни многочлена Чебышёва степени T (порядок не имеет значения):

$$\lambda_t = \frac{1}{2}(L + m) + \frac{1}{2}(L - m) \cos \left(\frac{(t - \frac{1}{2})\pi}{T} \right), \quad t = 1, \dots, T$$

Тогда алгоритм будет иметь скорость сходимости:

$$\|x - x^*\| \leq 2 \left(1 - \frac{2}{\sqrt{\kappa} + 1} \right)^T \|x_0 - x^*\|$$

Обычный градиентный спуск при оптимальном шаге $\alpha = \frac{2}{m+L}$ имеет скорость:

$$\|x - x^*\| \leq \left(1 - \frac{2}{\kappa + 1} \right)^T \|x_0 - x^*\|$$

Доказательство

Пусть $e_t = \|x_t - x^*\|$, $\nabla f(x_t) = (Ax_t - b)$.

$x_{T+1} = x_T - \alpha_T (Ax_t - b)$, $(Ax^* - b) = 0$, $x^* = x^* - \alpha_t (Ax^* - b)$.

Преобразуем это выражение: $x^* = x^* (I - \alpha_t A) - \alpha_t b$.

Тогда $e_{t+1} = x_{t+1} - x^* = x_{t+1} - x^* (I - \alpha_t A) - \alpha_t b = x_t - \alpha_t (Ax_t - b) - x^* (I - \alpha_t A) - \alpha_t b = x_t (I - \alpha_t A) - x^* (I - \alpha_t A) = (I - \alpha_t A)(x_t - x^*)$.

То есть $e_{t+1} = (I - \alpha_t A)e_t$.

Тогда $e_t = P_t(A)e_0$, где $P_t(\xi) = \prod_{i=1}^t (1 - \alpha_i \xi)$.

$\|e_t\| \leq \|P_t(A)\| \cdot \|e_0\|$.

A — симметричная матрица, значит $\|P_t(A)\| \leq \max_{\mu \leq \lambda \leq L} |P_t(\lambda)|$.

Среди всех многочленов степени t , наименьшее отклонение от нуля имеет многочлен Чебышёва степени t :

$$P_t(\lambda) = \left(1 - \frac{\lambda}{\lambda_1} \right) \left(1 - \frac{\lambda}{\lambda_2} \right) \dots \left(1 - \frac{\lambda}{\lambda_t} \right)$$

Тогда $P_k(\lambda) = T_k(\frac{\mu+L-2\lambda}{L-\mu})T_k(\frac{L+\mu}{L-\mu})^{-1}$ - многочлен Чебышёва, определенный на $[\mu, L]$ и нормированный. Оценим его норму: $|P_k(a)| \leq \frac{1}{T_k(\frac{L+\mu}{L-\mu})}$

Пусть $\frac{\mu+L}{L-\mu} = \frac{\kappa+1}{\kappa-1} = 1 + \varepsilon$ для некоторого $\varepsilon \approx \frac{2}{\kappa}$

Осталось только оценить $T_k(1+\varepsilon)$. По определению, для $x > 1$, $T_k(x) = \cosh(k \operatorname{arccosh}(x))$.

Пусть $\phi = \operatorname{arccosh}(1+\varepsilon)$. Из тригонометрического тождества следует $\sinh(\phi)^2 = \cosh(\phi)^2 - 1$. Тогда $\sinh(\phi) = \sqrt{(1+\varepsilon)^2 - 1} = \sqrt{\varepsilon^2 + 2\varepsilon}$.

По формуле Эйлера для гиперболических функций, $e^\phi = \cosh(\phi) + \sinh(\phi) = 1 + \varepsilon + \sqrt{\varepsilon^2 + 2\varepsilon} \geq 1 + \sqrt{\varepsilon}$. Тогда $T_k(1+\varepsilon) = \frac{e^{k\phi} + e^{-k\phi}}{2} \geq \frac{e^{k\phi}}{2} \geq \frac{(1+\sqrt{\varepsilon})^k}{2}$.

Тогда и $T_k(\frac{L+\mu}{L-\mu})^{-1} \leq 2(1+\sqrt{\varepsilon})^{-k}$

Отсюда имеем

$$\|e_k\| \leq 2(1+\sqrt{\varepsilon})^{-k} \|e_0\|$$

Доказано, что для квадратичных задач этот метод является оптимальным, не требует хранения данных о прошлых итерациях и, главное, широко применим в задачах с ограниченным вычислительным бюджетом. Действительно, стоит лишь заранее задать требуемое число итераций T и получить многочлен ошибки с минимально возможным максимумом нормы при этом числе итераций.

Легко видеть, что этот метод применим только для квадратичных функций. Нельзя ли некоторым образом адаптировать его для более широкого класса функций, традиционных для задач оптимизации, то есть сильно выпуклых, L - гладких функций (с константой выпуклости μ и липшицевой константой L)?

1 Адаптивное чебышёвское ускорение для неквадратичных функций

В классическом методе чебышёвского ускорения задача минимизации нормы ошибки сводится к минимаксной задаче для многочлена ошибки $P_n(A)$. Для неквадратичных функций с переменным Гессианом $A_i = \nabla^2 f(x_i)$ оператор ошибки вырождается в произведение:

$$P_n = (I - \eta_n A_n)(I - \eta_{n-1} A_{n-1}) \dots (I - \eta_1 A_1)$$

В гильбертовом пространстве для нормы произведения операторов справедливо неравенство $\|P_n\| \leq \prod_{i=1}^n \|I - \eta_i A_i\|$. Мы можем применить подход, аналогичный методу чебышёвского ускорения: минимизируем максимум нормы каждой скобки, представляя её как одночлен Чебышёва, определённый на промежутке $[\mu_i, L_i]$. Такой одночлен имеет единственный корень $x = \frac{\mu_i + L_i}{2}$, следовательно, шаг должен быть $\eta_i = \frac{2}{\mu_i + L_i}$.

В подтверждение корректности этих выкладок, покажем иной путь, приводящий к тем же выводам. Для нормального оператора A_i норма $\|I - \eta_i A_i\|$ совпадает с его спектральным радиусом $\rho(I - \eta_i A_i)$. Минимизация нормы итерационной скобки для матриц со спектром из $[\mu_i, L_i]$ сводится к минимаксной задаче:

$$\min_{\eta_i} \max_{\lambda \in [\mu_i, L_i]} |1 - \eta_i \lambda|$$

Оптимальное значение η_i достигается при условии равенства значений на концах интервала с противоположным знаком:

$$1 - \eta_i \mu_i = -(1 - \eta_i L_i) \implies 2 = \eta_i (L_i + \mu_i) \implies \eta_i = \frac{2}{\mu_i + L_i}$$

При этом значении норма каждой итерационной скобки минимальна и составляет $\frac{L_i - \mu_i}{L_i + \mu_i} < 1$, что гарантирует сходимость алгоритма при условии сильной выпуклости ($\mu_i > 0$).

2 Интерпретация

Данный подход имеет смысл интерпретировать как «аппроксимация второго порядка». В отличие от метода Ньютона, требующего обращения полной матрицы Гессияна, предлагаемый метод использует скалярную оценку кривизны $A_{cp} = \frac{m_i + L_i}{2}I$ с последующим ее обращением. Алгоритм адаптирует длину шага без изменения направления градиентного спуска (в отличие от метода Ньютона), что делает этот метод в некотором смысле квазиньютоновским.

3 Оценка спектра гессияна

Для оценки спектра предлагается использовать метод, известный как Hessian-free Power Iterations.

Основная идея метода заключается в использовании конечно-разностной аппроксимации произведения Гессияна на произвольный вектор v :

$$\nabla^2 f(x_i)v \approx \frac{\nabla f(x_i + \epsilon v) - \nabla f(x_i)}{\epsilon}$$

где ϵ — малое положительное число. Таким образом, одна итерация степенного метода требует лишь одного дополнительного вычисления градиента в возмущенной точке. Алгоритм нахождения L_i на итерации k выглядит следующим образом:

1. Выбирается случайный вектор v_0 единичной нормы.
2. Выполняется итерационный процесс: $v_{j+1} = \frac{\nabla^2 f(x_i)v_j}{\|\nabla^2 f(x_i)v_j\|}$.
3. Оценка старшего собственного числа: $L_i \approx v_j^T (\nabla^2 f(x_i)v_j)$.

Для поиска μ_i предлагается использовать спектральный сдвиг: поиск аналогичным образом максимального собственного числа $\lambda_{\max}(B_i)$ у вспомогательного оператора $B = L_i I - A_i$.

$$\lambda_{\max}(B_i) = L_i - \mu_i$$

. Тогда $\mu_i = L_i - \lambda_{\max}(B_i)$.

Если приблизительно известно число обусловленности или хотя бы его порядок, в случаях, когда κ достаточно большое, то есть $L_i \gg \mu_i$, имеет смысл применять эвристическую оценку μ_i . Например, $\mu_i = \alpha L_i$, где α есть некоторая подходящая константа. Очевидно, что в случаях $L_i \gg \mu_i$, μ_i слабо влияет на шаг $\frac{2}{L_i + \mu_i}$.

Стоит признать, что в худшем случае приходится трижды вычислять градиент на каждой итерации. Вместе с тем стоит отметить, что в этом методе все параметры строго определены, в отличие от эвристических методов, требующих также затратного подбора гиперпараметров (например, через GridSearch).

4 Инерция

Для многочленов Чебышёва определено рекуррентное соотношение

$$T_{k+1}(z) = 2zT_k(z) - T_{k-1}(z)$$

Для задачи оптимизации на $[\mu, L]$ используется нормированный многочлен $P_k(\lambda) = \frac{T_k(z(\lambda))}{T_k(z(0))}$. Обозначим $z_0 = z(0) = \frac{L+\mu}{L-\mu} > 1$. Тогда рекурсия для P_k принимает вид:

$$P_{k+1}(\lambda) = \frac{2z(\lambda)T_k(z_0)P_k(\lambda) - T_{k-1}(z_0)P_{k-1}(\lambda)}{T_{k+1}(z_0)}$$

Пусть $\omega_k = \frac{T_k(z_0)}{z_0 T_{k+1}(z_0)}$. Подставив их и учитывая, что $z(\lambda) = z_0(1 - \frac{2}{L+\mu}\lambda)$, получаем:

$$P_{k+1}(\lambda) = 2\omega_k z_0^2 (1 - \frac{2}{L+\mu}\lambda) P_k(\lambda) - \frac{\omega_k}{\omega_{k-1}} P_{k-1}(\lambda)$$

Поскольку $e_k = P_k(A)e_0$, мы можем переписать это для векторов ошибок $e_k = x_k - x^*$:

$$x_{k+1} - x^* = \alpha_k (I - \eta \nabla)(x_k - x^*) + \beta_k (x_{k-1} - x^*)$$

После некоторых алгебраических преобразований можно получить:

$$x_{k+1} = x_k - \eta_k \nabla f(x_k) + \gamma_k (x_k - x_{k-1})$$

То есть, в методе Чебышёвского ускорения, подобно методу тяжелого шарика, присутствует слагаемое инерции. Нельзя ли и в предложенный выше метод добавить таковое? Учитывая, что мы в ходе метода узнаем о кривизне функции достаточно, имеет смысл попытаться использовать эту информацию для построения оптимального γ_k