

Эвристический подход к адаптации чебышёвского ускорения для задач выпуклой оптимизации

Дмитрий Егоров

Научный руководитель:
д.ф.м.н., проф. О. Н. Граничин

Математико-механический факультет
Санкт-Петербургский государственный университет

2026 г.

Теорема Янга (Young's theorem, 1950)

Рассмотрим квадратичную форму $f(x) = \frac{1}{2}x^T Ax - b^T x$, где A имеет число обусловленности $\kappa = \frac{L}{m}$.

Градиентный спуск: $x_{t+1} = x_t - \eta_t \nabla f(x_t)$, x^* — точка минимума.

Выберем $\eta_t = \frac{1}{\lambda_t}$, где λ_t — корни многочлена Чебышёва степени T (порядок не имеет значения):

$$\lambda_t = \frac{1}{2}(L + m) + \frac{1}{2}(L - m) \cos\left(\frac{(t - \frac{1}{2})\pi}{T}\right), \quad t = 1, \dots, T$$

Тогда алгоритм будет иметь скорость сходимости:

$$\|x - x^*\| \leq 2 \left(1 - \frac{2}{\sqrt{\kappa} + 1}\right)^T \|x_0 - x^*\|$$

Обычный градиентный спуск при оптимальном шаге $\alpha = \frac{2}{m+L}$ имеет скорость:

$$\|x - x^*\| \leq \left(1 - \frac{2}{\kappa + 1}\right)^T \|x_0 - x^*\|$$




Рис.: Квадратичная плохообусловленная ($\kappa = 100$) функция

Пусть $e_t = \|x_t - x^*\|$, $\nabla f(x_t) = (Ax_t - b)$.

$x_{t+1} = x_t - \eta_t(Ax_t - b)$, $(Ax^* - b) = 0$, $x^* = x^* - \eta_t(Ax^* - b)$.

Преобразуем это выражение: $x^* = x^*(I - \eta_t A) - \eta_t b$.

Тогда

$$e_{t+1} = x_{t+1} - x^* = x_{t+1} - x^*(I - \eta_t A) - \eta_t b = x_t - \eta_t(Ax_t - b) - x^*(I - \eta_t A) - \eta_t b = x_t(I - \eta_t A) - x^*(I - \eta_t A) = (I - \eta_t A)(x_t - x^*).$$

То есть $e_{t+1} = (I - \eta_t A)e_t$.

Тогда $e_t = P_t(A)e_0$, где $P_t(\xi) = \prod_{i=1}^t (1 - \eta_i \xi)$.

$$\|e_t\| \leq \|P_t(A)\| \cdot \|e_0\|.$$

A — симметричная матрица, значит $\|P_t(A)\| \leq \max_{\mu \leq \lambda \leq L} |P_t(\lambda)|$.

Среди всех многочленов степени t , наименьшее уклонение от нуля имеет многочлен Чебышёва степени t :

$$P_t(\lambda) = \left(1 - \frac{\lambda}{\lambda_1}\right) \left(1 - \frac{\lambda}{\lambda_2}\right) \dots \left(1 - \frac{\lambda}{\lambda_t}\right)$$

$P_k(\lambda) = T_k(\frac{\mu+L-2\lambda}{L-\mu})T_k(\frac{L+\mu}{L-\mu})^{-1}$ - нормированный в нуле многочлен Чебышёва, определённый на $[\mu, L]$.

$$|P_k(a)| \leq \frac{1}{T_k(\frac{L+\mu}{L-\mu})}$$

$$\frac{L+\mu}{L-\mu} = \frac{\kappa+1}{\kappa-1} = 1 + \varepsilon, \varepsilon \approx \frac{2}{\kappa}$$

Оценим $T_k(1 + \varepsilon)$. Для $x > 1$ $T_k(x) = \cosh(k \cdot \operatorname{arccosh}(x))$. Пусть $\phi = \operatorname{arccosh}(1 + \varepsilon)$. Из тригонометрического тождества следует $\sinh(\phi) = \sqrt{(1 + \varepsilon)^2 - 1} = \sqrt{\varepsilon^2 + 2\varepsilon}$. По формуле Эйлера для гиперболических функций,

$$e^\phi = \cosh(\phi) + \sinh(\phi) = 1 + \varepsilon + \sqrt{\varepsilon^2 + 2\varepsilon} \geq 1 + \sqrt{\varepsilon}$$

$$T_k(1 + \varepsilon) = \frac{e^{k\phi} + e^{-k\phi}}{2} \geq \frac{e^{k\phi}}{2} \geq \frac{(1 + \sqrt{\varepsilon})^k}{2}$$

Тогда и

$$T_k(\frac{L+\mu}{L-\mu})^{-1} \leq 2(1 + \sqrt{\varepsilon})^{-k}$$

Можно ли адаптировать этот метод для неквадратичных функций?

Предлагаемая стратегия:

- 1 **Локальный анализ:** Оценка спектра Гессиана $[\mu_k, L_k]$ в текущей точке и построение оптимального полинома Чебышёва степени N .
- 2 **Цикл ускорения:** Выполнение N шагов градиентного спуска с длинами, обратными к корням построенного многочлена.
- 3 **Рестарт:** Полная переоценка спектра и обновление параметров каждые N итераций.

Проблема: для сильно нелинейных функций при $N > 1$ возникает эффект "устаревания" параметров спектра, что ведёт к расходимости. *Это мотивирует переход к $N = 1$ — адаптации шага на каждой итерации.*




Рис.: Сходимость на задаче логистической регрессии

$$f(w) = \frac{1}{n} \sum_{i=1}^n \ln(1 + e^{-y_i x_i^T w}) + \frac{\mu}{2} \|w\|_2^2$$

Адаптивное ускорение

Для неквадратичных функций с переменным Гессианом $A_i = \nabla^2 f(x_i)$ оператор ошибки выражается в произведение:

$$P_n = (I - \eta_n A_n)(I - \eta_{n-1} A_{n-1}) \dots (I - \eta_1 A_1)$$

$$\|P_n\| \leq \prod_{i=1}^n \|I - \eta_i A_i\|$$

Применим аналогичный подход: минимизируем норму каждой скобки отдельно, представляя её как *многочлен Чебышёва первой степени*, определённый на $[\mu_i, L_i]$.

Такой одночлен имеет единственный корень $x = \frac{\mu_i + L_i}{2}$. Отсюда следует выбор оптимального шага:

$$\eta_i = \frac{2}{\mu_i + L_i}$$

Спектральный подход к выбору шага

Минимизация нормы итерационной скобки $\|I - \eta_i A_i\|$ для матриц со спектром из $[\mu_i, L_i]$ сводится к минимаксной задаче:

$$\min_{\eta_i} \max_{\lambda \in [\mu_i, L_i]} |1 - \eta_i \lambda|$$

Оптимальное значение η_i достигается при равенстве значений на концах интервала с противоположным знаком:

$$1 - \eta_i \mu_i = -(1 - \eta_i L_i) \implies 2 = \eta_i (L_i + \mu_i)$$

$$\eta_i = \frac{2}{L_i + \mu_i}$$

При таком выборе норма итерационной скобки минимальна:

$$\|I - \eta_i A_i\| = \frac{L_i - \mu_i}{L_i + \mu_i} < 1$$

Это гарантирует сходимость алгоритма при условии локальной сильной выпуклости ($\mu_i > 0$).




Рис.: сходимость на задаче нелинейного МНК,
$$F(a, b, c) = \frac{1}{2} \sum_{i=1}^m (a \sin(bt_i) + c - y_i)^2$$

Метод Ньютона:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

Предложенный метод:

$$x_{k+1} = x_k - \frac{2}{\mu_i + L_i} \nabla f(x_k)$$

Мы осуществляем некоторую среднюю оценку кривизны $\frac{\mu_i + L_i}{2}$ и обращаем её, что делает этот метод в каком-то смысле квазиньютоновским.

Оценка спектра гессиана

Для оценки спектра гессиана без его явного вычисления предлагается использовать алгоритм, известный как Hessian - free power iterations.

- ❶ Выбирается случайный вектор v_0 единичной нормы ($\|v_0\| = 1$).
- ❷ Выполняется итерационный процесс (степенной метод):
 - Вычисляется аппроксимация произведения Гессиана на вектор (HVP) через конечные разности градиентов:

$$y_j = \frac{\nabla f(x_i + \epsilon v_j) - \nabla f(x_i - \epsilon v_j)}{2\epsilon}$$

- Вектор обновляется для следующей итерации: $v_{j+1} = \frac{y_j}{\|y_j\|}$
- ❸ Оценка старшего собственного числа получается как норма последнего вычисленного y_j :

$$L_i \approx \|y_j\|$$

μ_i можно вычислить аналогично, как L_i матрицы $B = L_i I - H$




Рис.: Функция Розенброка $f(x) = \sum_{i=1}^{d-1} [100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2]$ при $d = 5$, начальная точка $(-1.2, -1.0, -1.2, -1.0, -1.2)$

Для многочленов Чебышёва имеет место рекуррентное соотношение

$$T_{k+1}(z) = 2zT_k(z) - T_{k-1}(z)$$

Для оптимизации на $[\mu, L]$ используется нормированный полином ошибки $P_k(\lambda) = \frac{T_k(z(\lambda))}{T_k(z(0))}$, где $z(\lambda) = \frac{L+\mu-2\lambda}{L-\mu}$.

Подстановка $e_k = P_k(A)e_0$ приводит рекурсию к виду:

$$x_{k+1} = x_k - \eta_k \nabla f(x_k) + \gamma_k (x_k - x_{k-1})$$



Luo, T. *Algorithm Design Automation* [Электронный ресурс] // YouTube. — URL: <https://www.youtube.com/watch?v=ngBxHnRCVfc>.



Hardt, M. *Course Notes for EE227C: Convex Optimization and Approximation*. Lecture 6: Discovering acceleration [Электронный ресурс] // UC Berkeley. — URL: <https://ee227c.github.io/code/lecture6.html>.



Поляк, Б. Т. *Введение в оптимизацию*. — М.: Наука, 1983. — 386 с.